BAB 7 ANTRIAN (QUEUING THEORY)

Penyusun: Ir.M Nasri AW, M.Eng.Sc, M.Kom / Dosen STIEI Malang

A. POKOK BAHASAN DAN TUJUAN PEMBELAJARAN

Pokok Bahasan:

1. Konsep dan struktur dasar Antrian.
2. Perumusan model dan variabel pada dalam menyelesaikan antrian.
3. Analisis biaya antrian.

Tujuan Pembelajaran:

1. Memahami konteks antrian dalam kegiatan bisnis dan perilaku antrian.
2. Mendeskripsikan variabel dan merumuskan model antrian.
3. Menganalisis masalah antrian dan biaya untuk mengelola antrian.

Antrian adalah fakta kehidupan sehari-hari. Kita mengantri di bank, di rumah sakit, di gerai tol, bahkan di restoran cepat saji. Dari perspektif pelanggan, antrian adalah pemborosan waktu yang menimbulkan frustasi. Dari perspektif bisnis, antrian adalah pedang bermata dua. Antrian yang terlalu panjang dapat menyebabkan kehilangan pelanggan dan kerugian reputasi. Namun, menambah kapasitas pelayanan (misalnya, membuka lebih banyak teller) untuk menghilangkan antrian sepenuhnya dapat menyebabkan biaya yang tinggi karena sumber daya (pegawai, mesin) menganggur.

Teori Antrian (Queuing Theory) adalah cabang matematika yang mempelajari fenomena antrian. Teori ini bukan tentang menghilangkan antrian, melainkan tentang mengelolanya secara optimal. Tujuannya adalah menemukan keseimbangan yang ekonomis antara biaya pelayanan dan biaya yang ditimbulkan oleh waktu tunggu pelanggan. Dengan menggunakan model matematis, kita dapat memprediksi karakteristik antrian (seperti rata-rata waktu tunggu atau panjang antrian) dan mengevaluasi berbagai alternatif perbaikan sistem.

B. STRUKTUR DASAR SISTEM ANTRIAN

Setiap sistem antrian, terlepas dari bentuknya, dapat diuraikan menjadi tiga komponen utama:

1. Proses Kedatangan (Arrival Process): Ini menjelaskan bagaimana pelanggan (atau "entitas", seperti pesan di server, mobil di jalan tol) masuk ke dalam sistem. Karakteristik utamanya adalah laju kedatangan, yang dinyatakan dengan simbol λ (lambda), yaitu jumlah rata-rata pelanggan yang tiba per satuan waktu (misalnya, 20 pelanggan per jam). Dalam banyak model, kedatangan diasumsikan bersifat acak dan mengikuti distribusi Poisson. Ini berarti kedatangan satu pelanggan tidak bergantung pada kedatangan pelanggan lainnya.

2. Disiplin Antrian (Queue Discipline): Ini adalah aturan yang menentukan bagaimana pelanggan dipilih dari antrian untuk dilayani. Disiplin yang paling umum adalah:
3. FIFO (First-In, First-Out): Pertama datang, pertama dilayani. Ini adalah aturan yang paling adil dan paling sering digunakan di bank, toko, dll.
4. LIFO (Last-In, First-Out): Terakhir datang, pertama dilayani. Contohnya adalah barang yang ditumpuk di gudang.
5. SIRO (Service in Random Order): Pelanggan dipilih secara acak dari antrian.
6. Priority: Pelanggan dengan prioritas lebih tinggi dilayani terlebih dahulu (misalnya, penumpang kelas bisnis di bandara, pasien darurat di rumah sakit).
7. Mekanisme Pelayanan (Service Mechanism): Ini menjelaskan proses pelayanan itu sendiri. Dua karakteristik utamanya adalah:
    a. Jumlah Pelayan (Server, s): Jumlah fasilitas pelayanan paralel yang tersedia (misalnya, jumlah teller di bank, jumlah kasir di toko, jumlah dokter di klinik).
    b. Laju Pelayanan: Dinyatakan dengan simbol μ (mu), yaitu jumlah rata-rata pelanggan yang dapat dilayani oleh satu server per satuan waktu ketika server tersebut sibuk (misalnya, satu teller dapat melayani 30 pelanggan per jam). Waktu pelayanan sering diasumsikan mengikuti distribusi Eksponensial, yang berarti sebagian besar pelayanan berlangsung cepat, tetapi ada beberapa yang memakan waktu sangat lama.

Terdapat 3 jenis antrian, yaitu: Antrian jalur tunggal, pelayanan tunggal, antrian jalur ganda, pelayanan tunggal dan Antrian jalur tunggal, pelayanan ganda. Gambar berikut menggambarkan jenis antrian tersebut

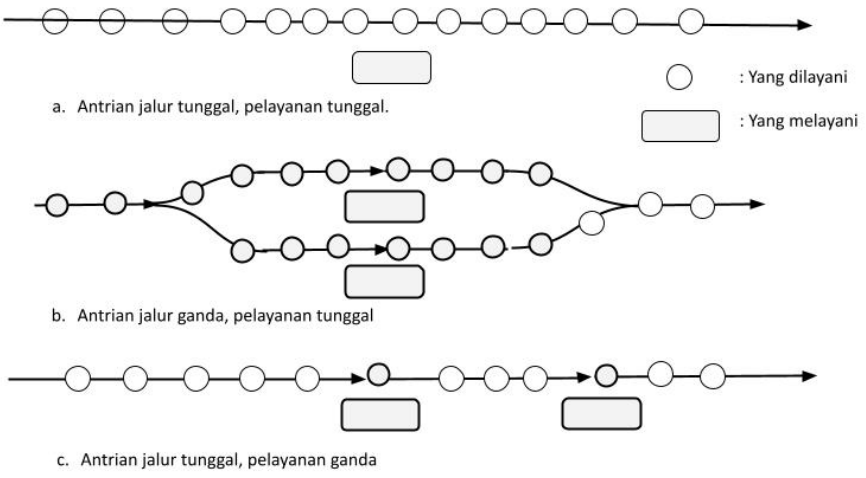

Gambar 3 Sketsa Antrian Dengan Jumlah Jalur dan Pelayanan

C. NOTASI DAN MODEL ANTRIAN

Untuk mengklasifikasikan berbagai jenis sistem antrian, kita menggunakan Notasi Kendall dengan format A/B/s.

A: Distribusi probabilitas waktu antar kedatangan.
B: Distribusi probabilitas waktu pelayanan.
s: Jumlah server paralel.

Simbol yang umum digunakan untuk A dan B adalah:

1. M: Markovian (Memoryless). Ini mengacu pada distribusi Poisson untuk kedatangan dan distribusi Eksponensial untuk pelayanan. Ini adalah asumsi yang paling umum dalam model dasar.
2. D: Deterministik atau Waktu Tetap. Waktu antar kedatangan atau waktu pelayanan selalu konstan (misalnya, mobil di conveyor belt).
3. G: General. Distribusi probabilitas apa pun dengan mean dan varians yang diketahui.

Contoh:

M/M/1: Kedatangan Poisson, waktu pelayanan Eksponensial, 1 pelayanan (server). Model dasar yang akan kita pelajari.
M/M/3: Kedatangan Poisson, waktu pelayanan Eksponensial, 3 pelayanan paralel.
M/D/2: Kedatangan Poisson, waktu pelayanan tetap, 2 pelayanan paralel.

D. ANALISIS MODEL ANTRIAN DASAR (M/M/1)

Model M/M/1 adalah model yang paling sederhana dan paling fundamental. Asumsinya adalah: kedatangan mengikuti proses **Poisson**, waktu pelayanan mengikuti distribusi Eksponensial, ada satu pelayanan, dan antrian dapat tumbuh tak terbatas.

Syarat Stabilitas:

Agar antrian tidak tumbuh tak terbatas hingga tak terkendali, laju kedatangan (λ) harus lebih kecil dari laju pelayanan (μ).

$$\lambda < \mu$$

Jika $\lambda \geq \mu$, sistem akan menjadi tidak stabil dan antrian akan terus memanjang dari waktu ke waktu.

Distribusi kedatangan (x) terhadap laju kedatangan (λ) mengikuti distribusi Poisson (sumber Wiki: https://id.wikipedia.org/wiki/Distribusi_Poisson) dirumuskan sebagai berikut:

Dalam suatu antrian kedatangan kendaraan x, antrian 1 pelayanan dengan laju kedatangan (λ), Probability (kedatangan atau arrival =x) dirumuskan:

$$Prob(Arrivals=x) = \frac{e^{-\lambda t}(\lambda t)^x}{x!}$$

Keterangan:

λ = Laju kedatangan

t = waktu kedatangan

x =Jumlah kedatangan

Untuk Contoh, dengan rumus distribusi Poisson, Laju kedatangan, $\lambda = 2$, dalam satuan waktu t = 1, Probabilitas kedatangan kendaraan x, seperti tabel 1 dan Gambar 2:

Tabel 1. Data Antrian

t	Prob of x
0	0,1353
1	0,2707
2	0,2707
3	0,1804
4	0,0902
5	0,0361
6	0,0120
7	0,0034
8	0,0009

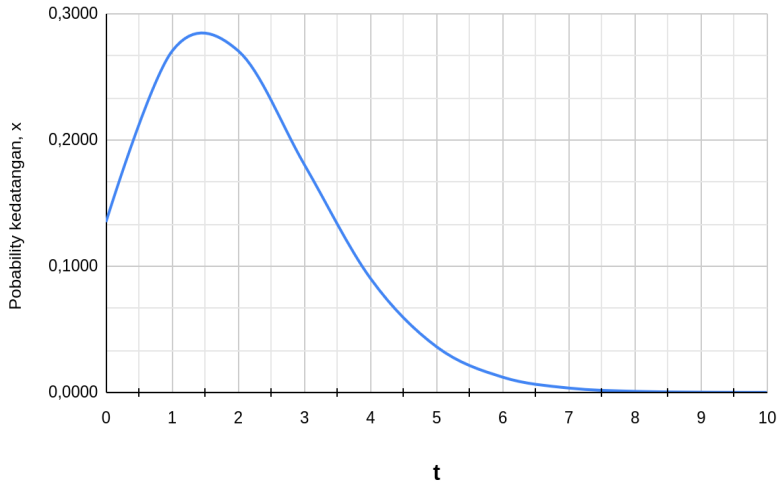

Gambar 2 Distribusi Kedatangan Dalam Antrian (Distribusi Poisson)

Keterangan gambar 2: Probabilitas kedatangan kendaraan x akan meningkat sampai t=2 (nilai sama dengan laju kedatangan di pelayanan, $\lambda = 2$, dan akan menurun setelah melewati pelayanan.

- Pengukuran Kinerja (Performance Measures):

Model M/M/1 memberikan rumus (lihat Tabel 2) untuk menghitung metrik kinerja kunci. Mari kita definisikan terlebih dahulu:

λ: Laju kedatangan rata-rata (pelanggan/jam).

μ: Laju pelayanan rata-rata per server (pelanggan/jam).

ρ (rho): Tingkat utilisasi server (proporsi waktu server sibuk). $\rho = \lambda / \mu$.

Tabel 2 Rumus Antrian

Pengukuran Kinerja	Simbol	Rumus	Interpretasi
Rata-rata jumlah pelanggan dalam sistem (antrian + dilayani)	L	$L = \frac{\lambda}{\mu - \lambda}$	Jumlah orang rata-rata yang ada di sistem.

Rata-rata jumlah pelanggan dalam antrian	Lq	$L_q = \frac{\lambda^2}{\mu(\mu-\lambda)}$	Jumlah orang rata-rata yang sedang mengantri.
Rata-rata waktu yang dihabiskan pelanggan dalam sistem	W	$W = \frac{1}{\mu-\lambda}$	Total waktu dari saat tiba hingga selesai dilayani.
Rata-rata waktu yang dihabiskan pelanggan untuk mengantri	Wq	$W_q = \frac{\lambda}{\mu(\mu-\lambda)}$	Waktu yang dihabiskan hanya untuk menunggu di antrian
Probabilitas sistem kosong (server menganggur)	P0	$P_0 = 1 - \rho = 1$	Peluang bahwa tidak ada pelanggan di sistem

Hubungan Little: Perhatikan bahwa $L = \lambda W$ dan $L_q = \lambda W_q$. Ini adalah hubungan fundamental yang berlaku untuk banyak sistem antrian.

E. MODEL ANTRIAN DENGAN BEBERAPA SERVER (M/M/S)

Model M/M/s adalah perluasan alami dari M/M/1, di mana terdapat `s` server identik yang bekerja paralel. Pelanggan membentuk satu antrian tunggal dan pelanggan pertama di antrian akan dilayani oleh server pertama yang tersedia.

Syarat Stabilitas:

Agar sistem stabil, laju kedatangan harus lebih kecil dari total laju pelayanan.

$\lambda < s\mu$

Penghitungan metrik kinerja untuk M/M/s lebih kompleks dan seringkali memerlukan tabel atau perangkat lunak. Namun, konsepnya sama. Rumus untuk Lq, misalnya, adalah:

$$L_q = \frac{P_0(\lambda/\mu)^s \rho}{s!(1-\rho)^2}$$

di mana P_0 (probabilitas sistem kosong) dan ρ (tingkat utilisasi) perhitungannya lebih rumit. Intinya, dengan menambah server, kita akan melihat penurunan drastis pada Lq dan Wq.

F. ANALISIS BIAYA TOTAL DALAM SISTEM ANTRIAN

Tujuan akhir dari analisis antrian adalah pengambilan keputusan ekonomis. Manajer ingin meminimumkan biaya total sistem, yang merupakan jumlah dari dua komponen yang saling berlawanan:

1. Biaya Pelayanan (Service Cost, Cs): Biaya untuk menyediakan dan menjalankan kapasitas pelayanan. Ini termasuk gaji pegawai, biaya sewa mesin, dll. Biaya ini bertambah seiring bertambahnya jumlah server (s).
2. Biaya Tunggu (Waiting Cost, Cw): Biaya yang timbul karena pelanggan menunggu. Ini adalah biaya yang sulit diukur, bisa berupa kerugian goodwill, pelanggan yang pergi,

atau bahkan biaya produktivitas yang hilang (jika yang mengantri adalah karyawan). Biaya ini berkurang seiring bertambahnya jumlah server.

Total Biaya (TC) = Biaya Pelayanan + Biaya Tunggu

$$TC = s \cdot C_s + L \cdot C_w$$

(Catatan: Beberapa model menggunakan Lq untuk biaya tunggu, tergantung apakah biaya hanya terjadi saat mengantri atau selama di sistem).

Tujuannya adalah menemukan jumlah server (s) yang menyeimbangkan kedua biaya ini sehingga Total Biaya minimum. Gambar 3 menunjukkan biaya untuk antrian antara biaya waktu tunggu dan biaya pengadaan layanan.

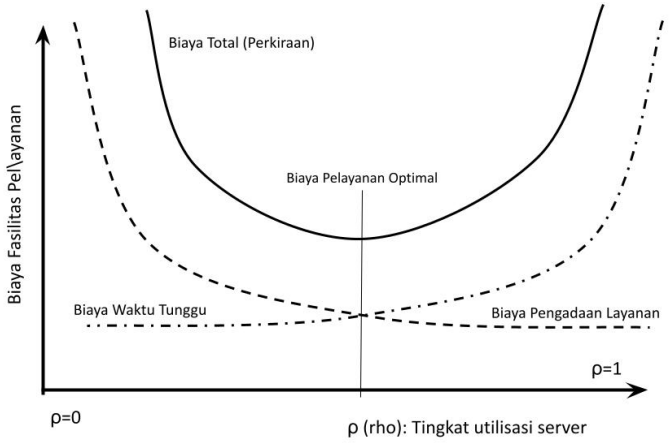

Gambar 3 Grafik Biaya Total yang menunjukkan kurva Biaya Pelayanan naik, Biaya Tunggu turun, dan Total Biaya berbentuk U

Contoh Kasus 1: Antrian di Pusat Layanan Gudang

Sebuah perusahaan yang menyewakan furniture mempunyai satu gudang dengan satu mesin pengangkut yang dioperasikan oleh satu kelompok yang terdiri dari tiga orang tenaga kerja.

Pemimpin perusahaan melihat pada jam-jam tertentu terjadi antrian truk tetapi di saat lain, petugas yang mengoperasikan mesin menganggur. Dari data yang telah lalu, diketahui rata-rata kedatangan 4 truk per jam (λ), dan rata-rata pelayanan 6 truk per jam (μ)

Rata-rata satuan pelayanan menggunakan rumus:

a. λ = rata-rata 1 kedatangan yang akan dilayani, misal kedatangan: 4 truck/jam

b. μ = rata-rata menyelesaikan 1 pelayanan, misal pelayanan bongkar: 6 truck/jam

ρ (rho): Tingkat utilisasi pelayanan (proporsi waktu sibuk). $\rho = \lambda / \mu$ = 4/6=0,66 atau 66 %.

Analisis indikator antrian dan Bagaimana jika menambah jumlah pelayanan menjadi 2 atau 3.

Perhitungan indikator antrian:

1. Jumlah pelayanan rata-rata sistem, L(s): $Ls = \frac{\lambda}{|\mu - \lambda|} = \frac{4}{|6-4|} = 2$
   Jumlah rata-rata truk dilayani sistem: 2 kend/jam

2. Jumlah rata-rata dalam antrian, L(q): $Lq = \frac{\lambda^2}{\mu . |\mu - \lambda|} = \frac{4^2}{6.|6-4|} = \frac{16}{6 \cdot 2} = 1,33$
   Jumlah rata-rata truk dalam antrian: 1,33 kend/jam

3. Waktu rata-rata pelayanan dalam sistem, Ws: $Ws = \frac{1}{|\mu - \lambda|} = \frac{1}{|6-4|} = 0,5$
   Waktu rata-rata truck dilayani sistem: 0,5 jam/kend

4. Waktu rata-rata dalam antrian, Wq: $Wq = \frac{\lambda}{\mu . |\mu - \lambda|} = \frac{4}{6.|6-4|} = \frac{4}{12} = 0,33$
   Waktu rata-rata truck dalam antrian: 0,33 jam/kend

Bagaimana jika menambah jumlah pelayanan menjadi 2 atau 3, Gambar 4 berikut menggambarkan perhitungan dengan menambah kelompok pekerja menjadi 2 dan 3 kelompok (1 kelompok 3 orang).

No	Indikator antrian	Rumus Perhitungan, (lambda=a, miu=b)	Rata-kedatangan truck/jam	Indikator Antrian		
				1 Kelompok	2 Kelompok	3 Kelompok
			a	Rata-rata Pelayanan, truck/jam = b		
			4	6	12	18
1	Jumlah rata-rata dilayani sistem, L(s):	Ls = a/(b-a)		2,000	0,500	0,286
2	Jumlah rata-rata dalam antrian, L(q):	Lq = a^2/(b(b-a))		1,333	0,167	0,063
3	Waktu rata-rata dilayani sistem, Ws:	Ws = 1/(b-a)		0,500	0,125	0,071
4	Waktu rata-rata dalam antrian, Wq:	Wq = a/(b(b-a))		0,333	0,042	0,016

Gambar 4 Indikator Antrian Jika Menambah Kelompok Pelayanan Gudang

Perhitungan menunjukkan dengan menambah kelompok layanan gudang, akan menurunkan rata-rata jumlah yang dilayani (L(s), jumlah dalam antrian, waktu dilayani sistem dan waktu dalam antrian. Perlu dihitung berapa biaya menambah kelompok pelayanan dan waktu yang dihemat dalam pelayanan gudang tersebut.

Contoh Kasus 2: penugasan Customer Service Representative (CSR)

Pusat layanan pelanggan (call center) "Maju Terus" menerima rata-rata 20 panggilan per jam (λ = 20). Saat ini, mereka hanya memiliki 1 orang Customer Service Representative (CSR) yang dapat menangani rata-rata 25 panggilan per jam (μ = 25). Manajemen menerima keluhan bahwa waktu tunggu terlalu lama. Biaya gaji per CSR adalah Rp 150.000 per jam. Manajemen

memperkirakan biaya tunggu (kerugian goodwill dan potensi kehilangan pelanggan) adalah Rp 100.000 per panggilan per jam.

Analisis biaya dan bagaimana jika menambah 1 CSR.

Penyelesaian:

Analisis Situasi Saat Ini (M/M/1):

$\rho = \lambda / \mu = 20 / 25 = 0.8$ (Server sibuk 80% waktu).

$Wq = \lambda / [\mu(\mu - \lambda)] = 20 / [25(25-20)] = 20 / 125 = 0.16$ jam = 9.6 menit.

$L = \lambda / (\mu - \lambda) = 20 / (25-20) = 4$ pelanggan rata-rata dalam sistem.

Biaya Total per Jam:

Biaya Pelayanan = 1 CSR Rp 150.000 = Rp 150.000

Biaya Tunggu = L Cw = 4 pelanggan Rp 100.000 = Rp 400.000

Total Biaya = Rp 550.000 per jam.

Evaluasi Alternatif: Menambah 1 CSR (M/M/2):

Sekarang, s = 2, sehingga total laju pelayanan adalah 2 25 = 50. $\lambda < s\mu$ (20 < 50), sistem stabil. Menggunakan kalkulator antrian M/M/s atau tabel, kita dapatkan:

$Wq \approx 0.017$ jam = 1.02 menit.

$L \approx 0.83$ pelanggan rata-rata dalam sistem.

Biaya Total per Jam:

Biaya Pelayanan = 2 CSR Rp 150.000 = Rp 300.000

Biaya Tunggu = L Cw = 0.83 Rp 100.000 = Rp 83.000

Total Biaya = Rp 383.000 per jam.

Rekomendasi: Menambah satu CSR akan mengurangi waktu tunggu rata-rata dari 9.6 menit menjadi sekitar 1 menit, dan mengurangi total biaya sistem dari Rp 550.000 menjadi Rp 383.000 per jam. Berdasarkan analisis ini, manajemen sangat disarankan untuk menambah satu CSR.

G. RANGKUMAN, PERTANYAAN DAN DISKUSI

Teori Antrian menyediakan lensa kuantitatif untuk menganalisis dan mengelola salah satu masalah paling umum dalam operasi layanan. Kita telah mempelajari struktur dasar sistem antrian dan cara mengklasifikasikannya dengan Notasi Kendall. Model M/M/1 dan M/M/s memberikan kita alat yang powerful untuk memprediksi metrik kinerja seperti panjang antrian dan waktu tunggu. Yang terpenting, kita telah memahami konsep kunci dari manajemen operasi: trade-off antara biaya pelayanan dan biaya tunggu. Dengan menganalisis biaya total, manajer dapat membuat keputusan yang didukung data tentang kapasitas pelayanan yang optimal, mencapai keseimbangan antara kepuasan pelanggan dan efisiensi biaya.

PERTANYAAN DAN DISKUSI

1. Mengapa masalah antrian perlu diperhatikan, apa akibat jika antrian lebih banyak dari pelayanan
2. Perhatikan di sekeliling kita, berikan contoh antrian dengan:
    a. Antrian jalur tunggal, pelayanan tunggal
    b. antrian jalur ganda, pelayanan tunggal
    c. Antrian jalur tunggal, pelayanan ganda
3. Apa yang harus dipertimbangkan dalam mengatasi antrian.

TUGAS 4: ANALISIS DAN PERBAIKAN SISTEM ANTRIAN PADA KASUS NYATA

Pilih satu sistem antrian di dunia nyata yang dapat Anda amati (misalnya: antrian di kantin kampus, loket pembayaran tiket bioskop, teller bank, atau drive-thru restoran cepat saji).

1. Pengamatan dan Estimasi Data:
    a. Amati sistem selama periode waktu tertentu (misalnya 1 jam pada jam sibuk).
    b. Estimasi laju kedatangan (λ): Hitung berapa pelanggan yang datang dalam 1 jam.
    c. Estimasi laju pelayanan (μ): Ukur waktu pelayanan untuk beberapa pelanggan, lalu hitung rata-ratanya. Konversi menjadi "pelanggan per jam" (misal: jika rata-rata waktu pelayanan 3 menit, maka $\mu = 60/3 = 20$ pelanggan/jam).
    d. Hitung jumlah server (s).
2. Analisis Model:
    a. Identifikasi model antrian yang sesuai (misalnya M/M/1 atau M/M/s).
    b. Hitung metrik kinerja utama: L, Lq, W, Wq.
    c. Periksa syarat stabilitas ($\lambda < s\mu$). Apakah sistem stabil?
3. Laporan Perbaikan (maksimal 2 halaman):
    a. Jelaskan karakteristik sistem yang Anda amati.
    b. Presentasikan hasil perhitungan kinerja Anda. Apakah waktu tunggu atau panjang antrian tergolong baik atau buruk? Jelaskan.
    c. Usulkan satu alternatif perbaikan (misalnya: menambah server, mempercepat proses pelayanan).
    d. Lakukan analisis "what-if" sederhana: Hitung kembali metrik kinerja jika perbaikan Anda diterapkan. Berapa peningkatan kinerjanya?
    e. Berikan rekomendasi akhir Anda kepada manajer tempat tersebut.

DAFTAR PUSTAKA

1. Bhat, U. N. (2021). An Introduction to Queueing Theory: Modeling and Analysis in Applications (2nd ed.). Birkhäuser. (Buku yang memberikan fondasi matematis yang kuat namun tetap accessible).
2. Gross, D., Shortle, J. F., Thompson, J. M., & Harris, C. M. (2021). Fundamentals of Queueing Theory (5th ed.). Wiley. (Buku teks rujukan standar dan paling komprehensif di bidang ini).
3. Hillier, F. S., & Lieberman, G. J. (2021). Introduction to Operations Research (11th ed.). McGraw-Hill Education. (Bab tentang teori antrian sangat jelas dan sarat contoh).
4. Lakshmi, C. R., & Iyer, S. (2020). "Application of queueing theory in health care: A literature review". Operations Research for Health Care, 25, 100236. (Artikel review yang fokus pada aplikasi di sektor kesehatan).
5. Liu, Y., Whitt, W., & Zhao, X. (2020). "Queuing models with random arrivals and deterministic service times: A review". Probability in the Engineering and Informational Sciences, 34(4), 530-561. (Membahas model M/D/s yang relevan untuk sistem otomatis).
6. hortle, J. F., Thompson, J. M., Gross, D., & Harris, C. M. (2022). Fundamentals of Queueing Theory (5th ed.). Wiley. (Edisi terbaru dari referensi klasik).
7. Taha, H. A. (2022). Operations Research: An Introduction (11th ed.). Pearson. (Penjelasan yang sangat baik dan mudah diikuti untuk mahasiswa pemula).
8. Tiwari, N., & Kumar, S. (2021). "A systematic literature review on the application of queueing theory in banking sector". International Journal of System Assurance Engineering and Management, 12(5), 1316-1329. (Artikel yang fokus pada aplikasi di perbankan).
9. Wang, J., & Zhang, Y. (2021). "Queueing theory models for performance analysis of cloud computing systems". Journal of Systems Architecture, 119, 102269. (Contoh aplikasi modern di bidang komputasi awan).
10. Winston, W. L., & Goldberg, J. B. (2022). Operations Research: Applications and Algorithms (5th ed.). Cengage Learning. (Dikenal dengan contoh-contoh aplikasinya yang sangat kaya dan relevan).